

INSTITUTO DE EDUCACIÓN SUPERIOR



DEPARTAMENTO DE TECNOLOGÍA DIGITAL

BIG DATA Y CIENCIA DE DATOS

MINERÍA DE DATOS

TEMA

LAB 01 CALIFICADO:

CRISP-DM y SEMMA aplicados al dataset UCI Heart Disease

Estudiantes:

- Agreda Villacorta Gyanella
- Aranda Cuevas Trilce
- Gogin Cisterna Rodrigo
- Mayorca Parra Sara Camila
- Yupanqui Chahua Jhadir Abdel

PROFESORA

Pilar Rocío Sayán Mejía

Ciclo: V

LIMA – PERÚ

2026 – 1

**LABORATORIO CALIFICADO N° 01****CRISP-DM y SEMMA aplicados al dataset UCI Heart Disease****DOCENTE: Pilar Rocío Sayán Mejía**

CURSO: Minería de Datos — C64893

Semana 2 — Entrega: Semana 3

Tema: Metodologías de Minería de Datos — CRISP-DM y SEMMA**Laboratorio:** CRISP-DM y SEMMA con UCI Heart Disease (Cleveland)

DATOS DEL GRUPO	
Integrante 1 (Coordinador/a):	Yupanqui Chahua, Jhadir
Integrante 2:	Agreda Villacorta, Gyanela
Integrante 3:	Aranda Cuevas, Trilce
Integrante 4:	Mayorca Parra, Sara
Integrante 5:	Gogin Cisterna, Rodrigo
Sección:	Periodo: 2026-I

Actividad 1: Tabla de conceptos CRISP-DM y SEMMA

Completen la tabla con definiciones propias de cada concepto. No copien textualmente de los materiales ni usen IA para generar las respuestas.

Concepto / Elemento	Respuesta con tus propias palabras
1. CRISP-DM: ¿qué significa la sigla y qué proceso describe?	CRISP-DM (<i>Cross-Industry Standard Process for Data Mining</i>) es un ciclo que nunca se detiene con el fin de sacar valor de los datos. Esta metodología no solo se enfoca en llegar a construir modelos, llega a entender el problema del negocio, poder trabajar con los datos, y así, poder llegar y aplicar una solución. Esta es <i>cíclica</i> , permitiendo poder volver a etapas anteriores para lograr mejorar de forma continua los resultados. Resaltando que engloba tanto el lado técnico como el del negocio.
2. SEMMA: ¿qué significa la sigla y en qué contexto se desarrolló?	SEMMA (<i>Sample, Explore, Modify, Model, Assess</i>) desarrollada por SAS, es una metodología con enfoque principal en el análisis técnico de los datos. Se centra en seleccionar, explorar, transformar y poder modelar datos para <i>poder obtener resultados</i> . Este no considera de forma directa el contexto del negocio ni su implementación al final.
3. Fase 1 — Comprensión del negocio (Business Understanding)	Se define qué problema se desea resolver y definir el por qué es importante. Se establecen los objetivos y criterios de éxito de la organización y qué restricciones existen. Es base de todo el proceso.
4. Fase 2 — Comprensión de los datos (Data Understanding)	Se analizan los datos disponibles para comprender su contenido y su calidad. Se identifican posibles errores, valores que faltan, es importante ya que asegura que los datos permitan resolver el problema planteado.
5. Fase 3 — Preparación de los datos (Data Preparation)	Los datos se limpian, se transforman y organizan para poder ser usados en el modelado. La calidad de los datos realmente influye en el rendimiento del modelo.
6. Fase 4 — Modelado (Modeling)	Se aplican algoritmos de aprendizaje automático o métodos estadísticos, ya que así se pueden encontrar patrones, predicciones. Ajustando los parámetros se puede mejorar los resultados, convirtiendo datos a modelos útiles
7. Fase 5 — Evaluación (Evaluation)	Se analiza el desempeño del modelo utilizando métricas específicas como precisión o recall. Y no solo se evalúa el rendimiento técnico sino también si el modelo cumple con el objetivo del negocio planteado al comienzo.

8. Fase 6 — Despliegue (Deployment)	Una vez validado el modelo se implementa en el entorno real de la organización. Puede ser integrado en sistemas o reportes, incluso en herramientas que puedan ayudar a la toma correcta de decisiones de valor.
9. ¿Por qué CRISP-DM es cíclico e iterativo?	Debido a que el proceso permite poder regresar a las fases anteriores, cuando se obtiene nueva información, o cuando se presentan resultados que no son adecuados. Así el proyecto no es lineal, sino un ciclo de mejora continua, logrando que cada iteración se adapte mejor a los datos, el enfoque de objetivos o problema.
10. ¿Principal diferencia entre CRISP-DM y SEMMA?	CRISP-DM cubre todo el proceso de un proyecto, incluyendo la comprensión del negocio y la implementación final, lo que lo hace más completo para proyectos reales. En cambio SEMMA se enfoca principalmente en la parte técnica del análisis de datos y construir modelos, sin considerar directamente el entorno organizacional ni la aplicación práctica del modelo.

Identificación de variables del dataset UCI Heart Disease

Antes de trabajar con el código, es fundamental conocer qué representa cada variable. Lean la siguiente tabla y, en la columna "Valores posibles", verifiquen que los datos cargados coinciden con lo indicado. El grupo debe estar en condiciones de explicar oralmente qué significa cada variable.

Variable	Tipo	Descripción clínica	Valores posibles
age	Numérica	Edad del paciente en años	Entre 29 y 77
sex	Categórica	Sexo del paciente	1 = Masculino, 0 = Femenino
cp	Categórica	Tipo de dolor en el pecho (chest pain)	0=asintomático, 1=angina típica, 2=angina atípica, 3=dolor no anginoso
trestbps	Numérica	Presión arterial en reposo al ingreso (mm Hg)	Valores típicos: 94 – 200
chol	Numérica	Colesterol sérico en mg/dl	Valores típicos: 126 – 564
fbs	Categórica	¿Glucosa en ayunas > 120 mg/dl?	1 = Sí, 0 = No
restecg	Categórica	Resultados del electrocardiograma en reposo	0=normal, 1=anomalía ST-T, 2=hipertrofia ventricular
thalach	Numérica	Frecuencia cardíaca Máxima alcanzada durante ejercicio	Valores típicos: 71 – 202
exang	Categórica	Angina inducida por ejercicio	1 = Sí, 0 = No

Variable	Tipo	Descripción clínica	Valores posibles
oldpeak	Numérica	Depresión del segmento ST inducida por ejercicio	0.0 – 6.2
slope	Categórica	Pendiente del segmento ST en ejercicio máximo	0=descendente, 1=plana, 2=ascendente
ca	Numérica	Nº de vasos principales coloreados por fluoroscopia	0 a 3
thal	Categórica	Resultado de prueba de esfuerzo con talio (thallium)	1=normal, 2=defecto fijo, 3=defecto reversible
target	Categórica (objetivo)	Diagnóstico de enfermedad cardíaca — VARIABLE OBJETIVO	0 = sin enfermedad, 1 = con enfermedad

Actividad 2: Aplicación de CRISP-DM en Google Colab

Paso 1 — Fase 1: Comprensión del Negocio

Contexto: El Servicio de Cardiología del Hospital Cleveland registró datos clínicos de 303 pacientes. El objetivo es construir un modelo predictivo que apoye al equipo médico en la identificación de pacientes con riesgo de enfermedad cardíaca (target = 1).

Pregunta 1: Formula el problema de negocio como una pregunta analítica clara.

¿Cómo podemos predecir, a partir de los datos clínicos de los pacientes, si una persona tiene riesgo de padecer enfermedad cardíaca para apoyar la toma de decisiones médicas?

Pregunta 2: ¿Qué tipo de tarea de minería es esta? Justifica.

Es una tarea de clasificación, ya que se busca predecir una variable categórica (riesgo de enfermedad cardíaca = 1, no riesgo de enfermedad = 0), agrupando a los clientes según características clínicas

Pregunta 3: ¿Cuáles son los criterios de éxito desde el punto de vista del hospital? Menciona al menos 2 métricas.

Desde el hospital, el éxito se puede medir con recall para detectar enfermos, porque interesa identificar la mayor cantidad posible de pacientes con riesgo. También sirve la precisión, para evitar demasiadas alarmas falsas. Otra métrica útil es la accuracy, aunque en medicina no debe ser la única referencia.

Paso 2 — Fase 2: Comprensión de los Datos

Dataset cargado correctamente

Filas: 303 pacientes

Columnas: 14 variables

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
0	63.0	1.0	1.0	145.0	233.0	1.0	2.0	150.0	0.0	2.3	3.0	0.0	6.0	0
1	67.0	1.0	4.0	160.0	286.0	0.0	2.0	108.0	1.0	1.5	2.0	3.0	3.0	1
2	67.0	1.0	4.0	120.0	229.0	0.0	2.0	129.0	1.0	2.6	2.0	2.0	7.0	1
3	37.0	1.0	3.0	130.0	250.0	0.0	0.0	187.0	0.0	3.5	3.0	0.0	3.0	0
4	41.0	0.0	2.0	130.0	204.0	0.0	2.0	172.0	0.0	1.4	1.0	0.0	3.0	0

Interpretación: La tabla nos muestra un conjunto de datos, orientado al desarrollo de un modelo de clasificación supervisada, consta de 303 registros y 14 variables que integran dimensiones demográficas (edad, sexo), indicadores clínicos de reposo (presión arterial, colesterol) y métricas de pruebas de esfuerzo cardíaco. La estructura tabular presenta una mezcla de datos numéricos continuos y variables categóricas codificadas, dirigidas a predecir la variable objetivo binaria (target), la cual identifica si el paciente tiene cardiopatía o no.

=== TIPOS DE DATOS Y VALORES NULOS POR VARIABLE ===				
	Tipo	Nulos	% Nulo	Únicos
age	float64	0	0.00	41
sex	float64	0	0.00	2
cp	float64	0	0.00	4
trestbps	float64	0	0.00	50
chol	float64	0	0.00	152
fbs	float64	0	0.00	2
restecg	float64	0	0.00	3
thalach	float64	0	0.00	91
exang	float64	0	0.00	2
oldpeak	float64	0	0.00	40
slope	float64	0	0.00	3
ca	float64	4	1.32	4
thal	float64	2	0.66	3
target	int64	0	0.00	2

Interpretación: El análisis de integridad revela que el dataset posee una alta calidad de datos, con una ausencia casi total de valores nulos, registrando apenas una pérdida marginal en las variables ca (1.32%) y thal (0.66%), lo cual permite una imputación sencilla sin comprometer la validez del estudio. Estructuralmente, aunque la mayoría de los atributos están codificados como float64, el conteo de valores únicos confirma una convivencia entre variables continuas (como el colesterol) y categóricas binarias o multiclase (como el sexo o el tipo de dolor torácico), validando finalmente la variable target como un indicador entero ideal para un modelo de clasificación binaria.

Pregunta 4: ¿Cuántas variables tiene el dataset? ¿Cuáles presentan valores nulos?



El dataset tiene 14 variables en total. Las variables con valores nulos son ca con 4 valores faltantes y thal con 2 valores faltantes.

=== ESTADÍSTICAS DESCRIPTIVAS ===

	age	sex	cp	trestbps	chol	fb	restecg	thalach	exang	oldpeak	slope	ca	thal	target
count	303.00	303.00	303.00	303.00	303.00	303.00	303.00	303.00	303.00	303.00	303.00	299.00	301.00	303.00
mean	54.44	0.68	3.16	131.69	246.69	0.15	0.99	149.61	0.33	1.04	1.60	0.67	4.73	0.46
std	9.04	0.47	0.96	17.60	51.78	0.36	0.99	22.88	0.47	1.16	0.62	0.94	1.94	0.50
min	29.00	0.00	1.00	94.00	126.00	0.00	0.00	71.00	0.00	0.00	1.00	0.00	3.00	0.00
25%	48.00	0.00	3.00	120.00	211.00	0.00	0.00	133.50	0.00	0.00	1.00	0.00	3.00	0.00
50%	56.00	1.00	3.00	130.00	241.00	0.00	1.00	153.00	0.00	0.80	2.00	0.00	3.00	0.00
75%	61.00	1.00	4.00	140.00	275.00	0.00	2.00	166.00	1.00	1.60	2.00	1.00	7.00	1.00
max	77.00	1.00	4.00	200.00	564.00	1.00	2.00	202.00	1.00	6.20	3.00	3.00	7.00	1.00

Interpretación: El análisis descriptivo revela una población de estudio con una edad promedio de 54 años y una notable dispersión en los niveles de colesterol (chol), cuyo valor máximo de 564 mg/dl sugiere la presencia de valores atípicos que podrían sesgar el modelo. Se observa que el 46% de la muestra presenta riesgo cardíaco (target medio de 0.46), lo que indica un dataset equilibrado para el entrenamiento algorítmico, mientras que variables como la presión arterial sistólica (trestbps) y la frecuencia cardíaca máxima (thalach) muestran rangos fisiológicos coherentes con perfiles clínicos reales. La similitud entre la media y la mediana (percentil 50%) en la mayoría de los atributos sugiere distribuciones que, aunque requieren normalización por sus distintas escalas, mantienen una tendencia central estable para el análisis predictivo.


Distribución de la variable objetivo — target



Interpretación: La distribución de la variable objetivo revela un dataset altamente balanceado, donde el 54.1% de los pacientes no presenta enfermedad cardíaca frente al 45.9% que sí la padece. Esta proporción es ideal para el entrenamiento de modelos de aprendizaje automático, ya que evita los sesgos comunes de las clases mayoritarias y garantiza que métricas como la exactitud (accuracy) sean representativas del rendimiento real. Al no existir un desequilibrio severo, no será estrictamente necesario aplicar técnicas de remuestreo (como SMOTE), permitiendo proceder directamente a la fase de modelado con una base sólida de datos comparativos.

Pregunta 5: ¿El dataset está balanceado? ¿Qué impacto puede tener esto en el modelo?

Sí, está relativamente balanceado, 54.1% sin enfermedad y 45.9% con enfermedad. Eso ayuda a que el modelo no se incline demasiado por una sola clase, y hace que el aprendizaje sea más confiable.



Interpretación: El análisis bivariado de las variables categóricas revela factores de riesgo determinantes, destacando que los pacientes con angina inducida por ejercicio (exang = 1.0), un tipo de dolor torácico específico (cp = 4.0) y anomalías en los resultados de la prueba de esfuerzo (slope = 2.0 y thal = 7.0) presentan una incidencia de enfermedad cardíaca significativamente mayor. Por el contrario, variables como el azúcar en sangre en ayunas (fbs) no muestran una distinción clara entre las clases, lo que sugiere una baja capacidad predictiva individual. Estos patrones visuales confirman que el modelo de clasificación se beneficiará principalmente de los indicadores de estrés físico y sintomatología clínica, permitiendo priorizar estas características durante la fase de entrenamiento para mejorar la precisión diagnóstica.

Paso 3 — Fase 3: Preparación de los Datos

```
=== VALORES NULOS ANTES DE IMPUTAR ===
```

```
ca      4
thal    2
dtype: int64
```

```
Mediana imputada para ca : 0.0
Mediana imputada para thal: 3.0
```

```
=== VALORES NULOS DESPUÉS DE IMPUTAR ===
```

```
age      0
sex      0
cp       0
trestbps 0
chol     0
fbs      0
restecg  0
thalach  0
exang    0
oldpeak  0
slope    0
ca       0
thal     0
target   0
dtype: int64
```

Interpretación: Se aplicó una técnica de imputación por mediana para resolver la ausencia de valores en las variables ca (4 nulos) y thal (2 nulos), logrando así un dataset íntegro y libre de valores faltantes para las 14 dimensiones analizadas. La elección de la mediana (0.0 para ca y 3.0 para thal) asegura una limpieza de datos robusta que preserva la tendencia central de la muestra sin introducir sesgos por valores atípicos, garantizando que el modelo predictivo pueda procesar la totalidad de los 303 registros de manera consistente.

Pregunta 6: ¿Por qué imputamos con la mediana y no con la media? ¿En qué casos cambiarían la estrategia?

Usamos la mediana porque es más resistente a valores extremos y en este dataset hay variables con pocos valores y posible dispersión. Cambiaríamos la estrategia si la variable fuera más continua, simétrica y sin valores atípicos, donde la media podría representar mejor el centro de los datos.

```
=== MUESTRA DEL DATASET CODIFICADO ===
```

	age	sex	trestbps	chol	fbs	thalach	exang	oldpeak	ca	cp_2.0	cp_3.0	cp_4.0	restecg_1.0	restecg_2.0	slope_2.0	slope_3.0	thal_6.0	thal_7.0
0	63.0	1.0	145.0	233.0	1.0	150.0	0.0	2.3	0.0	0	0	0	0	1	0	1	1	0
1	67.0	1.0	160.0	286.0	0.0	108.0	1.0	1.5	3.0	0	0	1	0	1	1	0	0	0
2	67.0	1.0	120.0	229.0	0.0	129.0	1.0	2.6	2.0	0	0	1	0	1	1	0	0	1
3	37.0	1.0	130.0	250.0	0.0	187.0	0.0	3.5	0.0	0	1	0	0	0	0	1	0	0
4	41.0	0.0	130.0	204.0	0.0	172.0	0.0	1.4	0.0	1	0	0	0	1	0	0	0	0
5	56.0	1.0	120.0	236.0	0.0	178.0	0.0	0.8	0.0	1	0	0	0	0	0	0	0	0
6	62.0	0.0	140.0	268.0	0.0	160.0	0.0	3.6	2.0	0	0	1	0	1	0	1	0	0
7	57.0	0.0	120.0	354.0	0.0	163.0	1.0	0.6	0.0	0	0	1	0	0	0	0	0	0
8	63.0	1.0	130.0	254.0	0.0	147.0	0.0	1.4	1.0	0	0	1	0	1	1	0	0	1
9	53.0	1.0	140.0	203.0	1.0	155.0	1.0	3.1	0.0	0	0	1	0	1	0	1	0	1

Interpretación: Como fase final de la preparación de datos, se realizó un control de calidad exhaustivo que confirma la viabilidad técnica del dataset para el modelado. Tras los procesos de imputación y codificación, el conjunto de datos cuenta con 303 registros y 18 variables predictoras totalmente numéricas, sin presencia de valores nulos o inconsistencias de formato. Esta verificación garantiza que la estructura de entrada es óptima y cumple con los requisitos matemáticos necesarios para alimentar algoritmos de aprendizaje automático, asegurando estabilidad y eficiencia durante el entrenamiento del modelo de clasificación de riesgo cardíaco.

Paso 4 — Fase 4: Modelado

=== PARTICIÓN DE LOS DATOS ===

Total de registros : 303

Entrenamiento : 227

Prueba : 76

Distribución de clases en entrenamiento:

target

0 0.542

1 0.458

Name: proportion, dtype: float64

Distribución de clases en prueba:

target

0 0.539

1 0.461

Name: proportion, dtype: float64

=== MODELO ENTRENADO ===

DecisionTreeClassifier(max_depth=4, min_samples_leaf=5, min_samples_split=10,
random_state=42)

Profundidad del árbol : 4

Nodos hoja : 14

=== VARIABLES MÁS IMPORTANTES ===

cp_4.0 0.3945

ca 0.1624

thal_7.0 0.1482

age 0.1445

oldpeak 0.0585

slope_2.0 0.0575


thalach 0.0207

trestbps 0.0075

restecg_2.0 0.0063

sex 0.0000

dtype: float64



Interpretación: Tras el entrenamiento del modelo de Árbol de Decisión, los resultados confirman una fase de modelado sólida y técnicamente coherente. La partición de datos (75/25) se ejecutó con éxito, manteniendo una distribución de clases prácticamente idéntica entre los conjuntos de entrenamiento (45.8% con riesgo) y prueba (46.1%), lo que garantiza que la evaluación final sea justa y no esté sesgada. El modelo, configurado con una profundidad de 4 niveles para evitar el sobreajuste (overfitting), identifica al tipo de dolor torácico (cp_4.0) como el predictor más crítico con un peso del 39.45%, seguido por el número de vasos coloreados (ca) y la presencia de defectos reversibles (thal_7.0). Este orden de importancia no solo es matemáticamente relevante, sino que tiene un alto valor clínico, sugiriendo que el algoritmo ha logrado capturar los indicadores médicos más determinantes para la detección de cardiopatías.

Pregunta 7: ¿Por qué usamos stratify=y? ¿Qué significa max_depth=4?

Usamos stratify=y para mantener la misma proporción de clases en entrenamiento y prueba. max_depth=4 significa que el árbol de decisión solo puede crecer hasta cuatro niveles, lo que ayuda a evitar sobreajuste y mantiene el modelo más simple.

```
=== AJUSTE DE HIPERPARAMETROS ===
Mejor accuracy promedio en CV: 0.8154
Mejores hiperparametros      : {'criterion': 'gini', 'max_depth': 3, 'min_samples_leaf': 5, 'min_samples_split': 2}

=== TOP 5 CONFIGURACIONES DEL MODELO ===
mean_test_score  std_test_score param_criterion param_max_depth \
0      0.815362      0.055468      gini              3
1      0.815362      0.055468      gini              3
2      0.815362      0.055468      gini              3
3      0.815362      0.055468      gini              3
4      0.815362      0.055468      gini              3


param_min_samples_split  param_min_samples_leaf
0          15              8
1          10              8
2           5              8
3           2              8
4          15              5
```

Interpretación: Para optimizar el rendimiento del algoritmo, se realizó un ajuste de hiperparámetros mediante validación cruzada, logrando una exactitud (accuracy) promedio del 81.54% con una desviación estándar controlada del 0.05. La configuración ganadora definió un árbol de decisión más simplificado con una profundidad máxima de 3 y un mínimo de 5 a 8 muestras por hoja, lo que favorece la capacidad de generalización del modelo y reduce el riesgo de sobreajuste ante nuevos datos clínicos. Este resultado es altamente competitivo para un diagnóstico médico preliminar, ya que las cinco mejores combinaciones de parámetros muestran una estabilidad notable en el puntaje, validando la robustez de la arquitectura seleccionada para la predicción de riesgo cardíaco.

Paso 5 — Fase 5: Evaluación

```
=== EVALUACIÓN DEL MODELO ===  
... Accuracy: 0.7894736842105263  
  
Matriz de confusión:  
[[33  8]  
 [ 8 27]]  
  
Reporte de clasificación:  
              precision    recall  f1-score   support  
  
      0         0.80        0.80        0.80         41  
      1         0.77        0.77        0.77         35  
  
   accuracy          0.79          0.79          0.79          76  
  macro avg          0.79          0.79          0.79          76  
 weighted avg          0.79          0.79          0.79          76
```

Interpretación: La evaluación final sobre el conjunto de prueba arroja un accuracy del 78.9%, demostrando una capacidad de clasificación equilibrada y robusta para identificar pacientes en riesgo. Según la matriz de confusión, el modelo clasificó correctamente a 60 de los 76 pacientes (33 verdaderos negativos y 27 verdaderos positivos), manteniendo métricas de precisión y sensibilidad (recall) sumamente similares entre sí (alrededor del 77%-80% para ambas clases). Este balance es fundamental en el contexto médico, ya que indica que el algoritmo es igual de efectivo para detectar la presencia de la enfermedad como para descartarla, logrando un F1-score de 0.77 en la clase de riesgo, lo que valida la utilidad del modelo optimizado como una herramienta de apoyo al diagnóstico con un margen de error controlado.



Interpretación: La matriz de confusión visualiza el alto desempeño del modelo, confirmando que 60 de los 76 casos de prueba (79%) fueron clasificados correctamente. De forma específica, el algoritmo logró identificar a 33 pacientes sanos (Verdaderos Negativos) y a 27 pacientes con riesgo cardíaco (Verdaderos Positivos), manteniendo un margen de error simétrico con solo 8 falsos positivos y 8 falsos negativos. Esta distribución equilibrada de errores es clave en el ámbito médico, ya que demuestra que el modelo no presenta un sesgo hacia ninguna clase, logrando una capacidad de discriminación robusta que valida la efectividad de las variables clínicas seleccionadas y del ajuste de hiperparámetros realizado previamente.

Pregunta 8: En contexto médico, ¿qué es más crítico: minimizar falsos negativos o falsos positivos? Justifica.

Es más crítico **minimizar los falsos negativos**, porque un falso negativo significa decir que un paciente está sano cuando en realidad sí tiene enfermedad. En medicina eso puede retrasar el diagnóstico y el tratamiento.

Paso 6 — Fase 6: Despliegue

Pregunta 9: ¿Cuáles son las 3 variables más importantes? Contrástalas con la tabla de variables que completaron en la Actividad 1. ¿Tienen sentido clínico?

Las tres variables más importantes fueron cp_4.0, ca y thal_7.0. Sí tienen sentido clínico:

- cp se relaciona con el tipo de dolor en el pecho,
- ca indica el número de vasos principales observados,
- thal representa el resultado de la prueba de esfuerzo.

Todas están relacionadas con señales clínicas que ayudan a detectar enfermedad cardíaca.

Pregunta 10: ¿Cómo implementarían este modelo en el hospital? Describan el flujo desde que llega el paciente hasta que el médico recibe la alerta.

Cuando el paciente llega, se registran sus datos clínicos en el sistema. Luego esos datos se envían al modelo entrenado, que calcula el riesgo de enfermedad cardíaca. Si el resultado indica riesgo, el sistema genera una alerta para que el médico revise el caso con más detalle. Así el modelo funciona como apoyo en la toma de decisiones, no como reemplazo del especialista.

Actividad 3: Cuadro comparativo CRISP-DM vs. SEMMA


Completen el cuadro con al menos 7 criterios de comparación entre ambas metodologías. Luego respondan la pregunta 11.

Criterio de comparación	CRISP-DM	SEMMA
Origen / quién lo desarrolló	Surgió como un estándar abierto creado por empresas como IBM, SPSS y Daimler-Benz, con la idea de tener una guía común para proyectos de minería de datos en cualquier industria.	Fue desarrollado por la empresa SAS como parte de sus herramientas de análisis, pensado principalmente para trabajar con datos dentro de su propio entorno.
Número de fases	6 fases que cubren todo el proceso del proyecto.	5 etapas centradas en el tratamiento y análisis de datos.
¿Incluye comprensión del negocio?	Sí, contempla llevar el modelo a un entorno real para que genere valor.	No incluye esta etapa, ya que se enfoca más en el análisis que en la implementación.
¿Incluye fase de despliegue?	Sí, contempla llevar el modelo a un entorno real para que genere valor.	No incluye esta etapa, se enfoca más en el análisis que en la implementación.
Sectores de aplicación principales	Sectores como salud, finanzas, marketing, etc.	Se utiliza más en entornos analíticos o técnicos.
¿Es cíclico o lineal?	Es cíclico e iterativo, permite volver a fases anteriores para mejorar resultados.	Más secuencial
Criterio propio del grupo (agregar uno)	Más completo para proyectos reales, ya que guía desde el problema hasta su implementación.	Útil para análisis específicos de datos, pero puede quedarse corto en proyectos que requieren impacto real en una organización.

Pregunta 11: ¿Cuál metodología usarían para este proyecto del Hospital Cleveland y por qué? Argumenten con al menos 3 razones.

Usaríamos CRISP-DM porque se adapta mejor a este proyecto por tres razones: primero, permite entender bien el problema médico antes de modelar; segundo, incluye la preparación, evaluación y despliegue del modelo; y tercero, es una metodología cíclica, así que permite volver a etapas anteriores si algo no funciona bien. Además, su enfoque completo encaja mejor con un caso real como el del hospital.

Actividad 4: Mapa conceptual de CRISP-DM



Actividad 5: Reflexión grupal

1: ¿Qué fase de CRISP-DM les resultó más desafiante y por qué?

Integrante 1 (Yupanqui Jhadir): Para mí, lo más difícil fue la Fase 3 de Preparación de Datos, porque decidir cómo llenar los nulos en `ca` y `thal` sin alterar la realidad clínica del paciente nos dio muchas vueltas. Al final, elegir la mediana fue un alivio técnico, pero entender por qué era mejor que la media nos tomó un buen debate grupal.

Integrante 2 (Agreda Gyanella): Definitivamente la Fase 4 de Modelado me pareció la más retadora, sobre todo al configurar los hiper parámetros del árbol. Ver cómo el `max_depth` cambiaba drásticamente la precisión del modelo nos hizo entender que más complejidad no siempre significa mejores resultados.

2: ¿En qué momento necesitaron regresar a una fase anterior? Describan el caso específico.

Integrante 3 (Aranda Trilce): Tuvimos que retroceder de la Evaluación (Fase 5) a la Preparación de Datos (Fase 3) porque nos dimos cuenta de que el modelo estaba confundiendo las categorías de `ag` al leerlas solo como números. Fue un momento clave donde entendimos que sin el One-Hot Encoding nuestro modelo no iba a ser justo con la lógica médica.

Integrante 4 (Gogin Rodrigo): Recuerdo que en pleno entrenamiento del modelo volvimos a la Fase 2 de Comprensión para revisar de nuevo los gráficos de barras. Necesitábamos confirmar si la relación entre `exang` y el `target` era tan fuerte como el modelo decía, para estar seguros de que no había errores en la carga de datos.

3: ¿Qué descubrieron del dataset UCI Heart Disease que no esperaban?

Integrante 5 (Mayorca Sara): Me sorprendió muchísimo que el nivel de azúcar en sangre apenas influyera en las predicciones del árbol. Siempre asociamos diabetes con corazón, pero aquí los datos nos gritaron que el tipo de dolor y los resultados de la prueba de esfuerzo eran mucho más vitales.

Integrante 1 (Yupanqui Jhadir): No esperaba que el dataset fuera tan 'limpio' en cuanto a nulos, lo que nos facilitó la vida, pero me impactó ver casos con colesterol de más de 500 mg/dl. Ver esos valores extremos nos hizo poner los pies en la tierra sobre la gravedad de los pacientes que estábamos analizando.

4: ¿Cómo se organizaron como grupo? ¿Quién hizo qué? (Honestidad en esto no afecta la nota.)

Integrante 2 (Agreda Gyanella): Jhadir nos guio súper bien con la estructura del código, mientras que Trilce y yo (Agreda) nos sumergimos en los gráficos del EDA para entender cada variable. Fue interesante porque mientras unos debatíamos con la lógica del árbol, otros ya estábamos interpretando qué significaba la matriz de confusión.

Integrante 3 (Aranda Trilce): Rodrigo y Sara se enfocaron mucho en la limpieza de datos y en el reporte final, asegurándose de que la parte médica tuviera sentido. Nos comunicamos todo el tiempo por WhatsApp para que nadie se quedará atrás con los cambios que hacíamos en el notebook.

5: ¿Qué harían diferente si repitieran este proyecto?

Integrante 4 (Gogin Rodrigo): Si lo hiciéramos de nuevo, me encantaría probar con un modelo más potente como Random Forest para ver si superamos ese 79% de accuracy. También buscaría un dataset con más registros, porque con 303 pacientes sientes que cualquier cambio pequeño afecta mucho el resultado.

Integrante 5 (Mayorca Sara): Yo dedicaría más tiempo a crear nuevas variables, tal vez combinando la edad con la presión arterial para ver si esa mezcla nos daba pistas más claras. También intentaría hacer una interfaz visual más bonita para que un médico pudiera usar nuestro modelo de forma más sencilla.

CONCLUSIONES

Escriban al menos 3 conclusiones técnicas y de aprendizaje:

- La conclusión técnica más relevante es que el modelo de Árbol de Decisión no solo alcanzó una exactitud competitiva del 78.9%, sino que logró identificar patrones con alta coherencia médica. Variables como el tipo de dolor torácico (cp) y el número de vasos coloreados (ca) resultaron ser los predictores con mayor ganancia de información. Esto demuestra que la minería de datos, cuando se aplica correctamente sobre un dataset clínico, es capaz de replicar la jerarquía de síntomas que un especialista consideraría crítica para un diagnóstico de riesgo coronario.
- Aprendimos que la calidad del modelo final depende directamente del tratamiento previo de los datos. La implementación de imputación por mediana para los valores nulos en **ca** y **thal**, sumada a la expansión de dimensiones mediante One-Hot Encoding, fue lo que permitió que el algoritmo procesara la información sin sesgos jerárquicos erróneos. Sin esta fase de "limpieza y traducción", el modelo habría tenido un rendimiento significativamente inferior, lo que nos enseña que el éxito en Ciencia de Datos reside un 80% en la preparación y un 20% en el modelado.
- Desde una perspectiva de aprendizaje estratégico, concluimos que en salud no basta con tener un "Accuracy" alto; es vital analizar la Matriz de Confusión. En nuestro proyecto, lograr un equilibrio donde los falsos negativos se mantuvieran bajo control fue la prioridad, ya que omitir un caso de riesgo es mucho más costoso humanamente que realizar una prueba adicional por un falso positivo. Esta experiencia nos enseñó a evaluar modelos no solo como números, sino bajo el contexto del problema real que intentamos resolver.