Glosario Semana 2

En esta segunda semana se abordan las metodologías utilizadas en proyectos de minería de datos, enfocándose principalmente en CRISP-DM y SEMMA.
Estos enfoques permiten organizar el trabajo de manera estructurada, desde la comprensión del problema hasta la implementación de soluciones. El objetivo de este apunte es resumir los conceptos clave y entender cómo se aplican estas metodologías.

¿Por qué usar una metodología?

Guía estructurada para proyectos de datos. Permite organizar el proceso, mejorar resultados y asegurar que el análisis sea claro, reproducible y útil.

Proceso de Minería de Datos

Secuencia ordenada para analizar datos.

- **Metodologías principales:** CRISP-DM domina, SEMMA complementa.

CRISP-DM es la más usada en la industria, mientras SEMMA tiene un enfoque más técnico.

Tareas Comunes de Minería de Datos

Clasificación: Asignar categorías
Regresión: Predecir valores numéricos
Clustering: Agrupar datos similares
Reglas de asociación: Encontrar relaciones entre variables.

CRISP-DM

Metodología estándar para proyectos de datos. Modelo cíclico ampliamente usado que guía todo el proceso de minería de datos.

- **Fase 1 Comprensión del Negocio**: Entender el problema a resolver. Define objetivos, necesidades y contexto del negocio.
- **Fase 2 Comprensión de los Datos:** Analizar y entender los datos disponibles. Incluye recolección, revisión de calidad y EDA.
- **Fase 3 Preparación de Datos**: Limpiar y transformar datos. Se corrigen errores, se seleccionan variables y se integran datos.
- **Fase 4 Modelado:** Construir modelos predictivos. Se aplican algoritmos para encontrar patrones o hacer predicciones.
- **Fase 5 Evaluación:** Verificar calidad del modelo. Se usan métricas, validación cruzada y análisis de sesgos.
- **Fase 6 Despliegue:** Implementar el modelo en la realidad. El modelo se usa en producción para apoyar decisiones.

SEMMA

Metodología estándar para proyectos de datos. Modelo cíclico ampliamente usado que guía todo el proceso de minería de datos.

- **Sample (Muestreo)**: Seleccionar datos representativos.
- **Explore (Explorar):** Analizar y visualizar datos.
- **Modify (Modificar):** Transformar y preparar datos.
- **Model (Modelar):** Aplicar algoritmos.
- **Assess (Evaluar):** Verificar calidad del modelo. Se usan métricas, validación cruzada y análisis de sesgos.

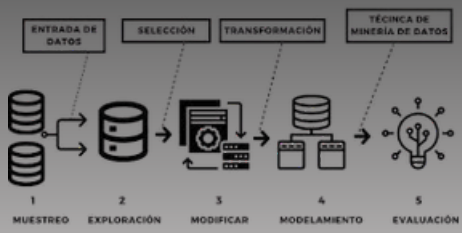

Concepto / Principio	Definición
1. CRISP-DM (definición y significado de las siglas)	CRISP-DM significa Cross-Industry Standard Process for Data Mining. Es una guía completa que no solo dice cómo analizar datos, sino cómo llevar todo el proyecto desde entender el problema hasta aplicar la solución en la vida real. Se diferencia porque incluye tanto el lado técnico como el del negocio.
2. SEMMA (definición y significado de las siglas)	SEMMA significa Sample, Explore, Modify, Model, Assess. Es una forma de trabajar más enfocada en los datos: primero los eliges, los exploras, los preparas y luego haces el modelo. Se centra más en el análisis técnico y no tanto en el contexto del negocio.
3. Comprensión del negocio (Business Understanding)	Se define qué problema se quiere resolver y por qué es importante. Es clave porque guía todo lo demás.
4. Comprensión de los datos (Data Understanding)	Aquí se revisan los datos para entender qué contienen y si sirven. Permite detectar errores o cosas raras antes de avanzar.
5. Preparación de datos (Data Preparation)	Es donde los datos se limpian, se ordenan y se seleccionan. Es una de las fases más importantes porque un modelo.
6. Modelado (Modeling)	En esta fase se aplican algoritmos para encontrar patrones o hacer predicciones. Es donde realmente se construye la solución.
7. Evaluación (Evaluation)	Aquí se revisa si el modelo funciona bien y si realmente soluciona el problema inicial.
8. Despliegue (Deployment)	Es cuando el modelo se usa en la vida real. Esta fase conecta el análisis con la toma de decisiones.
9. ¿Cuál es la principal diferencia entre CRISP-DM y SEMMA?	CRISP-DM abarca todo el proyecto, incluyendo entender el problema del negocio, mientras que SEMMA se enfoca más en trabajar directamente con los datos y construir modelos. Por eso CRISP-DM es más completo y usado en la práctica.